네트워크 침입 탐지에서 데이터셋 및 탐지 모델에 따른 XAI 설명의 충실도 비교*

백동명* 김선호* 이현우**

*한국에너지공과대학교 (대학생) **한국에너지공과대학교 (교수)

A Comparative Study of XAI Explanation Fidelity in Network Intrusion Detection across Datasets and Models

Dongmyeong Back*, SeonHo Kim*, Hyunwoo Lee**

*Korea Institute of Energy Technology (Undergraduate student), **Korea Institute of Energy Technology (Faculty)

요 약

딥러닝 기반 네트워크 침입 탐지 시스템(NIDS)은 고도화되는 사이버 공격을 탐지하기 위한 하나의 중요한 요소 기술로서 널리 활용되고 있다. 딥러닝은 기본적으로 판단 근거를 알기 어렵기 때문에, 이를 확인하기 위한 다양한 설명 가능 인공지능(XAI) 기법이 제시되었지만, NIDS에 대한 XAI 알고리즘들의 효과와 성능은 아직 체계적으로 연구되지 않았다. 본 연구에서는 8개 침입 탐지 데이터셋에 대해, 피드포워드(feedforward) 신경망과 XGBoost를 기반으로 한 두 가지 탐지 모델을 xNIDS와 Trustee 두 XAI 기법을 기반으로 분석하면서 설명의 충실도(fidelity)를 평가하였다. 충실도는 설명이 상위로 지목한 k개 특징을 치환한 뒤에도 탐지 모델의 예측이 유지되는 비율(DA_k)로 정량화하였으며, 또한 두 설명 기법이 선택한 상위 5개 특징의 일치율을 비교하였다. 실험 결과, 동일한 XAI 기법이라도 데이터셋과 탐지 모델에 따라 DA_5가 0.0에서 0.875까지 변화하였으며, 두 기법이 지목한 상위 5개 특징의 일치율은 모든 조합에서 0.54를 넘지 못하였다. 이는 XAI 기법의 신뢰성을 다른 환경으로 일반화하기 어려움을 보여준다.

I. 서론

네트워크 침입 탐지 시스템(NIDS)은 사이버 공격으로부터 네트워크를 보호하는 핵심 수단이다. 최근에는 탐지 성능 향상을 위해 대규모 네트워크 데이터로부터 복잡하고 비선형적인 패턴을 효과적으로 학습할 수 있는 딥러닝 및 트리 기반 모델이 널리 활용되고 있다 [1, 2].

그러나 이러한 모델은 판정 과정이 불투명하여 탐지 결과의 근거를 파악하기 어렵다. 경보를 받은 운영자는 해당 트래픽을 차단할지, 오탐으로 처리할지, 탐지 규칙을 수정할지를 결정해야 한다. 이때 모델이 어떤 특징을 근거로 공격을 판정했는지 알 수 있다면, 유사한 트래픽을 추가로 조사하거나 그 근거가 실제 공격과 무관한지를 검토하여 오탐 가능성을 판단할 수 있다. 이러한 의사결정을 지원하기 위해, 모델의 판정을 사람이 이해할 수 있는 근거로 제시하는 설명 가능한 인공지능(eXplainable AI, XAI) 기법이 주목 받고 있다 [3].

대표적인 XAI 기법으로는 국소적 설명을 생성하는 xNIDS [1]와 전역 대리 모델 기반의 Trustee [2]가 있다. 두 기법은 설명의 범위와 생성 방식이 달라 동일한 판정에도 서로 다른 특징을 중요하게 제시할 수 있다. 따라서 각 기법이 제시한 특징이 모델의 판정에 얼마나 기여하는지를 특징 유무에 따른 성능 차이를 측

* 이 연구는 2025년도 산업통상자원부 및 한국산업기술기획평가원(KEIT) 연구비 지원에 의한 연구임(과제번호 RS-2025-02653102)

정한 충실도를 바탕으로 비교하고, 데이터셋과 탐지 모델에 따른 비교 결과의 차이를 분석할 필요가 있다.

모델의 실제 근거와 무관하다고 볼 수 있으며, 보안 분야에서도 이러한 평가의 필요성이 지적되어 왔다 [3].

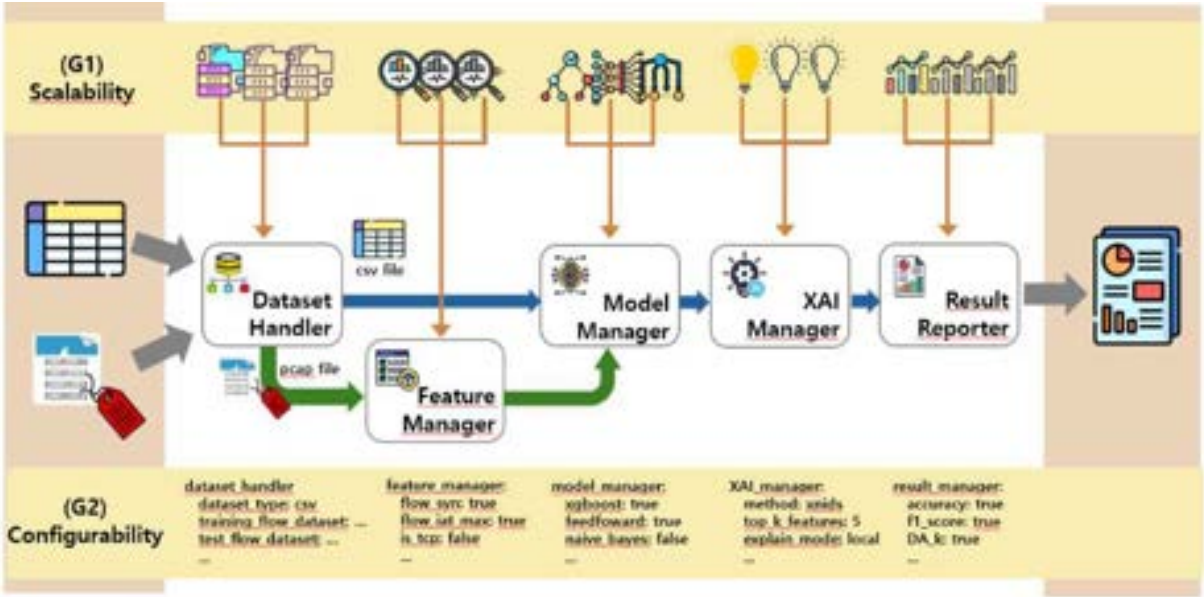


그림 1. XAI 평가 실험 절차

이에 본 연구에서는 8개 침입 탐지 데이터셋, 2개 탐지 모델, 2개 XAI 기법으로 구성된 32개 조합의 충실도를 특징 치환 기반의 DA_k와 두 기법이 선택한 상위 특징의 일치율을 활용하여 평가하였다.

II. 기존 설명 기법 및 평가 방법

xNIDS는 설명하려는 입력 데이터를 조금씩 바꾼 샘플을 여러 개 만들어, 각 샘플에서 탐지 모델의 판정이 어떻게 변화하는지를 관찰한다 [1]. 이후 입력 데이터의 변화와 판정의 변화 사이의 관계를 선형 모델로 근사하고, 판정을 크게 좌우한 특징을 찾는다. 개별 판정마다 설명을 새로 생성하므로 입력별로 다른 근거를 제시할 수 있다. 반면 Trustee는 결정트리 형태의 대리 모델을 탐지 모델 전체에 대해 증류(distillation)한 뒤, 개별 입력이 트리에서 지나간 경로의 분기를 설명으로 제시한다 [2]. 학습 데이터 전체를 하나의 대리 모델로 근사하므로 전역적인 판정 구조를 드러내는 데 유리하다.

이러한 설명의 품질은 설명이 지목한 특징을 치환했을 때 판정이 뒤집히는지로 판단할 수 있다 [4]. 판정이 그대로 유지된다면 그 설명은

III. 평가

실험 환경. 본 연구의 실험 절차는 그림 1과 같으며, 총 8개의 데이터셋을 활용하였다. 이들은 NSL-KDD, Mirai, UNSW-NB15, ToN-IoT를 비롯하여 BoT-IoT, N-BaIoT, CICIDS2017와 CICIDS2017에 보고된 레이블 및 특징 추출 오류를 보정한 CICIDS2017-imp [5]이다. 각 데이터셋에 대해 피드포워드 신경망(feedforward neural network, FNN)과 XGBoost 두 가지 탐지 모델을 학습하였다. 학습된 모델이 공격으로 분류한 입력만을 XAI 설명 생성 및 평가 대상으로 선정하였고, 각 입력에 대해 xNIDS와 Trustee로 설명을 생성하였다. 데이터셋·탐지 모델·XAI의 32가지 조합에서 설명의 충실도와 두 XAI 간 일치율을 측정하였다.

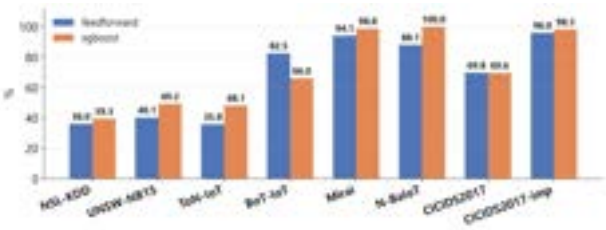


그림 2. 데이터셋별 탐지 모델 F1-score

탐지 모델 성능. 그림 2는 각 데이터셋에서 두

탐지 모델이 기록한 F1-score를 비교한 결과를 나타낸다. Mirai, N-BaIoT, CICIDS2017-imp에서는 두 모델 모두 88% 이상의 높은 성능을 보인 반면, NSL-KDD, UNSW-NB15, ToN-IoT에서는 50% 미만에 머물렀다. 또한 BoT-IoT에서는 FNN이 82.5%로 XGBoost의 66.0%를 상회하여, 모델 간 우열이 데이터셋에 따라 역전되는 경우도 확인되었다. 이는 이후의 설명 충실도가 탐지 모델의 성능이 다른 조건들 위에서 산출되었음을 의미한다.

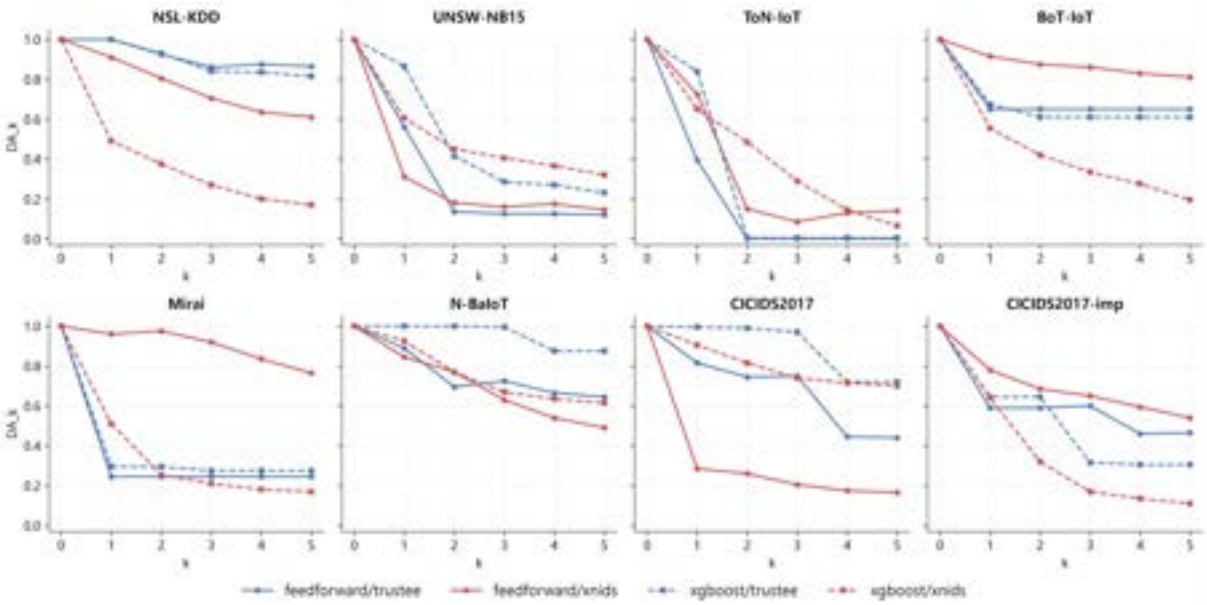


그림 3. 탐지 모델 - 설명 기법 조합별 DA_k 곡선

설명 충실도 비교. 그림 3은 각 조합의 DA_k 곡선을 나타낸다. DA_k는 설명이 상위로 지목한 k개 특징을 정상 트래픽의 평균값으로 치환한 뒤에도 원래의 공격 판정이 유지되는 입력의 비율로, 값이 낮을수록 XAI가 지목한 특징이 실제 판정에 기여했음을 의미한다. 가장 두드러진 결과는 DA_5를 기준으로 한 두 XAI 기법의 상대적 성능이 데이터셋과 탐지모델에 따라 달라진다는 점이다. NSL-KDD의 XGBoost에서는 xNIDS의 DA_5 값이 크게 낮았으나, BoT-IoT의 FNN에서는 반대로 Trustee가 더 낮았다. 또한, 동일한 XAI라도 탐지 모델에 따라 결과가 달라져, Mirai의 xNIDS는 FNN에서 0.765였던 DA_5가 XGBoost에서는 0.17까지 하락하였다. 전체적으로 DA_5는 0.0에서 0.875까지 분포하여, 설명 충실도가 데이터셋과 탐지 모델의 조합에 강하게 의존함을 보여준다.

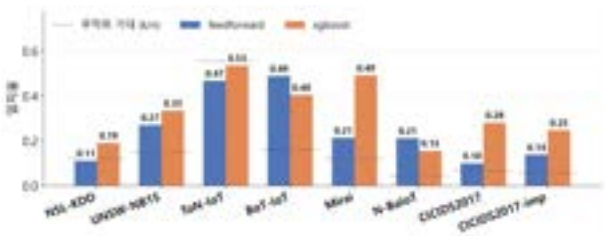


그림 4. 각 XAI기법의 상위 5개 특징 일치율

설명 간 일치도. Fig. 4는 두 XAI가 동일한 입력에 대해 선택한 상위 5개 특징 중 공통으로 선택된 특징의 비율, 즉 일치율을 나타낸다. 일치율은 모든 조합에서 0.54를 넘지 못하여, xNIDS 와 Trustee가 각각 다른 특징에 집중한다는 것을 보였다.

최상위 특징 비교. Table 1은 각 조합에서 가장 중요하게 지목된 최상위 특징을 정리한 것이다. Trustee는 여덟 데이터셋 중 일곱에서 두 탐지 모델에 대해 동일한 특징을 최상위로 지목한 반면, xNIDS는 Mirai를 제외한 모든 데이터셋에서 탐지 모델에 따라 서로 다른 특징을 지목하였다. 또한 두 기법이 같은 특징을 최상위로 선택한 경우는 BoT-IoT의 FNN과

CICIDS2017-imp의 XGBoost 두 조합에 불과하

데이터셋	FNN/xNIDS	FNN/Trustee	XGBoost/xNIDS	XGBoost/Trustee
NSL-KDD	동일 출발 포트 접속 비율	동일 서비스 접속 비율	출발지 전송 바이트	동일 서비스 접속 비율
UNSW-NB15	목적지 전송 속도	동일 목적지·출발 포트 연결 수	출발지 전송 바이트	동일 목적지·출발 포트 연결 수
ToN-IoT	송신 바이트 수	TCP 플래그	송신 패킷 수	TCP 플래그
BoT-IoT	패킷 일련번호	패킷 일련번호	기록 시작 시각	기록 종료 시각
Mirai	순방향 최대 패킷 길이	SYN 플래그 수	순방향 최대 패킷 길이	SYN 플래그 수
N-BaIoT	발신 호스트 패킷 크기 평균	발신 호스트 트래픽 양	호스트 쌍 지터 평균	발신 호스트 트래픽 양
CICIDS2017	목적지 포트	역방향 패킷 길이 표준편차	PSH 플래그 수	역방향 패킷 길이 표준편차
CICIDS2017-imp	목적지 IP	출발지 IP	출발지 IP	출발지 IP

Table 1. 탐지 모델 - 설명 기법 조합별 최상위 특징

였다. 다만 이때 지목된 특징은 각각 패킷 일련번호와 출발지 IP였으며, 두 데이터셋에서는 네 조합 모두 IP 주소·패킷 일련번호·기록 시각이 최상위로 나타나 [2]가 지적한 데이터셋 인공물 학습 문제가 재현되었다. 즉 두 기법의 근거가 일치한 경우조차 그것을 탐지의 타당한 이유로 보기는 어렵다. 이러한 결과는 하나의 XAI가 제시한 근거만으로 판정의 원인을 단정하기 어렵다는 점을 시사한다.

IV. 결론

본 연구는 8개 침입 탐지 데이터셋과 2개 탐지 모델, 2개 XAI 기법의 조합에 대해 설명 충실도를 측정하여, XAI의 충실도가 적용 대상에 따라 크게 달라짐을 확인하였다. 아울러 두 기법이 지목한 상위 5개 특징의 일치율은 모든 조합에서 0.54를 넘지 못하여, 두 기법이 동일한 판정에 대해 서로 다른 근거를 제시하고 있음을 보여준다. 따라서 NIDS에 XAI를 적용할 때에는 운영 환경의 데이터와 탐지 모델에 대해 충실도를 직접 측정하는 절차가 선행되어야 할 것이다. 후속 연구로 데이터셋에 따라 설명 충실도가 달라지는 원인을 규명하고자 한다.

[참고문헌]

[1] F.Wei, H.Li, Z.Zhao and H.Hu, xNIDS: Explaining Deep Learning-based Network Intrusion Detection Systems for Active Intrusion Responses, Proceedings of the 32nd USENIX Security Symposium, August, 2023.

[2] A.S.Jacobs, R.Beltiukov, W.Willinger, R.A.Ferreira, A.Gupta and L.Z.Granville, AI/ML for Network Security: The Emperor has no Clothes, Proceedings of the 2022 ACM SIGSAC Conference on Computer and Communications Security, pp.1537-1551, November, 2022.

[3] A.Nadeem, D.Vos, C.Cao, L.Pajola, S.Dieck, R.Baumgartner and S.Verwer, SoK: Explainable Machine Learning for Computer Security Applications, Proceedings of the 2023 IEEE 8th European Symposium on Security and Privacy, pp.221-240, July, 2023.

[4] V.Petsiuk, A.Das and K.Saenko, RISE: Randomized Input Sampling for Explanation of Black-box Models, Proceedings of the British Machine Vision Conference, September, 2018.

[5] L.Liu, G.Engelen, T.Lynar, D.Essam and W.Joosen, Error Prevalence in NIDS datasets: A Case Study on CIC-IDS-2017 and CSE-CIC-IDS-2018, 2022 IEEE Conference on Communications and Network Security, pp.254-263, October, 2022.